

Projet : Examen Final (02.06.2026)

A rendre : Samedi 06 Juin 2026 à 12h

Veuillez

- la note totale est sur **20** ;
- noter que l'examen comporte trois pages ;
- Former des groupes de quatre personnes.
- indiquer clairement et succinctement vos réponses correspondantes (et souligner ou encadrer les résultats numériques) ;
- apporter une attention particulière à la rédaction et à la définition des notations que vous employez.

1. Contexte

1.1 Le problème

La fraude fiscale représente un manque à gagner considérable pour les États. Aux États-Unis, l'IRS (Internal Revenue Service) estime le "*tax gap*" - différence entre impôts légalement dus et impôts effectivement collectés - à plus de **600 milliards de dollars** par an. L'automatisation de la détection d'anomalies dans les déclarations de revenus est donc un enjeu majeur pour les administrations fiscales.

Ce projet propose de construire un système complet de détection des déclarations de revenus potentiellement frauduleuses en mobilisant les outils de l'écosystème R, depuis l'analyse exploratoire jusqu'au déploiement d'une application de surveillance interactive.

Le jeu de données utilisé est l'**Adult Income Dataset** (aussi connu sous le nom « *Census Income* »), issu du recensement américain de 1994, disponible publiquement sur l'**UCI Machine Learning Repository**¹. Il contient **48 842 individus** et 15 variables socio-démographiques et économiques permettant de prédire si le revenu annuel d'un individu dépasse 50 000 \$, indicateur proximal du risque de sous-déclaration fiscale.

1.2 Description du jeu de données

Variable	Description	Type
age	Âge de l'individu	Numérique
workclass	Classe de travail (privé, public, indép.)	Catégorielle (8 niveaux)
fnlwgt	Poids de pondération finale	Numérique
education	Niveau d'éducation (16 niveaux)	Catégorielle
education.num	Niveau d'éducation (code numérique)	Numérique
marital.status	Statut marital	Catégorielle (7 niveaux)
occupation	Catégorie professionnelle	Catégorielle (14 niveaux)
relationship	Relation dans le foyer	Catégorielle (6 niveaux)
race	Origine ethnique	Catégorielle (5 niveaux)
sex	Sexe	Binaire
capital.gain	Gains en capital (USD)	Numérique
capital.loss	Pertes en capital (USD)	Numérique
hours.per.week	Heures travaillées / semaine	Numérique
native.country	Pays d'origine (41 niveaux)	Catégorielle
income (cible)	Revenu > 50K\$ (fraude proxy)	Binaire — <=50K / >50K

¹ <https://archive.ics.uci.edu/dataset/20/census+income>

2. Objectifs du projet

Objectif général : Développer un système complet d'aide à la décision pour la détection de contribuables à risque de sous-déclaration fiscale, allant de l'analyse exploratoire des données jusqu'au déploiement d'un tableau de bord interactif destiné aux agents de contrôle fiscal.

Plus spécifiquement :

Volet 1 : Analyse et préparation des données (Tidyverse)

- **O1.1** - Importer, nettoyer et standardiser le jeu de données Census Income (gestion des NA, renommage, types).
- **O1.2** - Réaliser une analyse exploratoire approfondie (distribution des variables, corrélations, déséquilibre de classes).
- **O1.3** - Créer des variables dérivées pertinentes : ratio capital gain/loss, tranche d'âge, score d'éducation, indicateur hautes heures.
- **O1.4** - Produire des visualisations analytiques avec ggplot2.

Volet 2 : Modélisation prédictive (Tidymodels)

- **O2.1** - Mettre en place un pipeline de pré-traitement reproductible (recipes) : encodage, normalisation, SMOTE, sélection de variables.
- **O2.2** - Utiliser la régression logistique avec pénalisation
- **O2.3** - Optimiser les hyperparamètres par validation croisée stratifiée (fixé la graine à 2026).
- **O2.4** - Sélectionner et interpréter le meilleur modèle (AUC ROC, F1).
- **O2.5** - Sauvegarder le modèle final.

Volet 3 — Rapport automatisé (R Markdown / Quarto)

- **O3.1** - Produire un rapport analytique reproductible intégrant texte, code, graphiques et tableaux.
- **O3.2** - Implémenter des rapports paramétrés par catégorie socio-professionnelle générés automatiquement.
- **O3.3** - Publier une version HTML interactive avec code masqué (code-fold) et Table de matière flottant.

Volet 4 — Application interactive (R Shiny)

- **O4.1** - Développer un dashboard de surveillance permettant de filtrer et explorer les profils à risque.
- **O4.2** - Intégrer le modèle de scoring en temps réel pour évaluer de nouvelles déclarations.

3. Livrables attendus

3.1 Livrable 1 — Scripts R de traitement et modélisation

Fichiers à rendre : Un fichier unique R avec les parties suivantes :

- **01_import.R** - Import du jeu UCI Adult avec `read_csv()`, nettoyage des valeurs manquantes ("?" → NA), renommage avec `janitor`, conversion des facteurs.
- **02_eda.R** - Analyse exploratoire : distribution de `income`, matrices de corrélation, profil moyen par classe, visualisations `ggplot2` (histogrammes, boxplots, heatmap).
- **03_feature_engineering.R** - Création de : `age_group` (tranche), `capital_net` = `capital_gain` - `capital_loss`, `high_hours` (`hours` > 50), `education_score` (ordinal), `has_capital` (indicatrice).
- **04_modelisation.R** - Pipeline `tidymodels` complet : `recipe()` + `workflow_set()`, `tune_grid()` 5-fold stratifié, sélection du meilleur modèle.
- **05_evaluation.R** - Évaluation finale : matrice de confusion, courbe ROC, courbe PR, importance des variables (`vip`), analyse des erreurs, `saveRDS()` du modèle final.

3.2 Livrable 2 — Rapport R Markdown

Fichier : `reports/rapport_fraude_fiscale.Rmd` / sortie : HTML + PDF

Le rapport doit contenir les sections suivantes :

	Section	Contenu attendu
1	Résumé exécutif	4 KPIs en code inline : n total, n >50K, taux, AUC final
2	Présentation des données	Description variable, NA, déséquilibre de classes (gt)
3	Analyse exploratoire	≥ 5 graphiques <code>ggplot2</code> commentés, tableau de corrélations
4	Feature Engineering	Justification des variables créées, distributions avant/après
5	Modélisation	Estimation des différents modeles
6	Évaluation du meilleur modèle	Matrice de confusion, AUC, F1, importance des variables
7	Rapport paramétré	1 rapport par occupation (walk + render), 5 professions minimum (catégories)
8	Conclusion & recommandations	Points clés

3.3 Livrable 3 — Application Shiny

Fichier : `R/app_fraude.R`

L'application doit comprendre 4 onglets :

Onglet	Titre	Fonctionnalités requises
1	Tableau de bord	4 KPI (n total, n >50K, taux risque, AUC), graphique temporel/par groupe, filtres sidebar
2	Exploration	Graphiques dynamiques selon variables choisies (<code>selectInput</code>), table DT filtrable et exportable
3	Scoring individuel	Formulaire de saisie d'un contribuable, score de risque en temps réel, jauge colorée (FAIBLE/MOYEN/ÉLEVÉ)